

# 数据噪声治理实战手册(Data-Centric AI Playbook)

Anker VLM 项目 · 2026-08-04 · 基于业界方法综述 + 本项目全部实测数据

配套 PDF:docs/data\_centric\_noise\_playbook.pdf

## 0. 摘要

大模型时代的共识:模型架构的边际收益递减,数据质量的边际收益仍然陡峭(data-centric AI)。

本项目的标签噪声治理已覆盖业界六大方法族中的全部可用项,核心结论:

- <b>1.</b> 我们的组合拳(描述 judge + 多证人合议 + 只升级纪律 + 删改分层 + 评测双口径)与业界 SOTA 实践一一对应,方向无需调整;
- <b>2.</b> 新补齐三件套:训练动力学日志(--cartography)、嫌疑软化通道(loss 降权)、置信学习交叉验证;
- <b>3.</b> 反直觉铁律(实测):清训练集会令冻结 test 的 RT 分不升反降(共享错标幻觉),清标验收只看 SubKS/人工,永远不看 test RT。

## 1. 病情画像

| 维度                           | 数字                                                   | 来源                                |
|------------------------------|------------------------------------------------------|-----------------------------------|
| 训练集                          | 83,561 条(去重后)                                        | labels_dedup.jsonl                |
| 测试集                          | 11,022 条,冻结、客户已验、永不清洗                                | labels_test.jsonl                 |
| RT 训练集错标(desc-judge)         | 4,240 = 5.1%(D 3061 / A 1075 / B 90 / E 14)          | gt_desc_judge_train.jsonl         |
| RT 测试集错标(desc-judge)         | 522 = 4.7%(D 8.5% > A 5.9% > E 0.8% > B 0.3% > C 0%) | test_mislabel_exclude_ids_522.txt |
| SubKS 测试集错标(desc-judge, 修正后) | 622 = 5.6%(e→b 424 系统性遛狗错标)                          | test_sk_mislabel_exclude_ids.txt  |
| SubKS 两证人嫌疑上限                | 882 = 8.0%(含主观边界,不可直接当错标)                            | 模型×盲判交叉                           |
| 本质模糊(全片都判不了)                 | RT 错误的 49% / SubKS 错误的 66%                           | 16 帧盲判分解                          |
| 关键帧缺失真实上限                    | RT 1.48pp / SubKS 4.01pp(事件类双双漏判)                    | 同上                                |

噪声结构三分:①客观错标(描述自打脸,可清)②主观边界(A↔D、e/f/m、k/l,清不动,只能软化)③瞬时事件漏标(帧间证据,需客户侧重切,收益上限小)。

## 2. 方法族总览

| # | 方法族             | 代表工作                                      | 本项目状态                         |
|---|-----------------|-------------------------------------------|-------------------------------|
| 1 | 置信学习            | Cleanlab / Northcutt 2021                 | 已跑(CL 615 条,∩judge 72 = 证人互补) |
| 2 | LLM-as-Judge 清洗 | FineWeb, Nemotron-CC                      | 主力(RT 4240 / SK 827→622)      |
| 3 | 训练动力学           | Dataset Cartography / AUM                 | 已落码(--cartography),清洗夜启用      |
| 4 | 噪声鲁棒训练          | label smoothing / co-teaching / DivideMix | 软化通道已落码(降权 0.3)               |
| 5 | 主观边界正规化         | learning from disagreement                | 纪律已建(只升级/不判 k-l-m)            |
| 6 | 测试集卫生           | ImageNet-ReaL / CIFAR-N                   | 双口径已接管线                       |

### 3. 置信学习(Confident Learning)

原理:对每类  $j$  估计"被标为  $j$  的样本的平均预测概率"作为类阈值  $t_j$ ;样本(标  $i$ )若对某类  $j \neq i$  的预测概率  $\geq t_j$ ,计入混淆联合  $C[i][j]$  的 off-diagonal  $\rightarrow$  嫌疑。比裸  $\arg\max$  稳健(类不平衡下阈值自适应)。

经典结论(Pervasive Label Errors, Northcutt 2021):ImageNet test 有  $\sim 6\%$

错标;模型会背测试集错标刷分,测试集越脏、大模型优势越被低估。本项目"剔 522 后 RT +1.26pp"就是该现象的复现。

本项目实测(S5 模型 RT 字母 logits, test 11022):

- CL 嫌疑 615 = 5.6%;方向  $A \rightarrow D$  236 /  $D \rightarrow A$  141(主观边界为主)
- 与 judge 522 只重合 72 条 —— 两个证人盲区互补:CL 看不见"模型已背下的共享错标"(模型附和错 GT 时 CL 无信号);judge 看不见"描述没写出来的错标"
- $\triangle$  CL 清单(`cl_rt_suspects_test.json`)只能用于训练集清洗排序/人工审计,绝不可当评测剔除口径(它使用了被测模型,不满足 model-independent)

落地:清洗夜产出新模型后,用其 train 集 logits 跑 CL,与 desc-judge 4240 取交集 = 最高置信错标(优先修),取差集 = 各自盲区(送人工抽审)。

### 4. LLM-as-Judge 清洗(主力方法)

设计要素(业界共识  $\leftrightarrow$  本项目实现):

- <b>1.</b> 只抓肯定性矛盾,模糊一律 ok("vague  $\rightarrow$  ok") —— 宁漏抓保精度
- <b>2.</b> 要求引用证据(cue 字段  $\leq 12$  词原文引用) —— rationale-required,防幻觉
- <b>3.</b> prompt 约束 + 代码硬闸双保险(ALLOWED\_TARGETS / NEVER\_DEMOTE / 身份闸)
- <b>4.</b> 试跑(分层抽样) $\rightarrow$  人工目测  $\rightarrow$  收紧  $\rightarrow$  全量,迭代闭环
- <b>5.</b> 删除比改判安全:三层口径 = 有旁证才修(1933)/ 单证只删或降权(2307)

两次实战教训:

- 第一轮试跑暴露"多主体场景"与"干活途中碰车"两个误杀模式  $\rightarrow$  prompt 加 MAIN-activity 约束,嫌疑率 4.1% $\rightarrow$ 3.0%
- SubKS 全量后审计发现  $m \rightarrow p$  系统性误杀 277 条:prompt 类定义没对齐父类语义( $p$ =野生动物,父类 LifeThreat;家猫家狗标  $E|m$  本来就对) $\rightarrow$  后过滤只留明确野生物种 70 条。教训:judge prompt 的类定义必须逐条对照权威 taxonomy 与父类分组写。
- $e \rightarrow b$  424 条( $e$  类的 46.5%! )是真 · 系统性错标:标注员把遛狗成批标进"休闲",94% 有旁证 —— 系统性错标一旦命中,单方向即可达全类近半,这是 judge 相对逐条人工审的核心价值。

### 5. 训练动力学(Dataset Cartography / AUM)

原理:训练过程中每样本每次相遇的 loss/margin 轨迹,天然把数据分三桶:

- 易学(低 loss 低方差)= 干净样本
- 难学但稳定(高 loss 低方差)= 真难例(保留!是泛化的养分)
- 高波动/低置信(高方差)= 疑似错标

这是唯一能区分"错标 vs 真难例"的免费证人 —— desc-judge 和 CL 都做不到这一点。

本项目实现(`train_sft.py --cartography`, 2026-08-04):

- `loss_fn` 借 `has_aux` 返回每样本加权 CE,零额外前向;宿主用 `draw()` 纯函数反推 `video_id`,预取器零改动
- 输出 `<out>/cartography.jsonl`:`{video_id, micro, loss}`,  $\sim 4.7 \text{ epoch} \times 83k \approx 39 \text{ 万行}$

- 分析:按 video\_id 聚合 → 均值(难度) × 方差(波动)二维图 → 高方差桶  $\cap$  judge/CL 嫌疑 = 铁证错标;高均值低方差  $\cap$  嫌疑 = 大概率真难例,从清洗清单摘除

用法:清洗夜训练命令加 `--cartography`,一次训练白捡第四证人。

## 6. 噪声鲁棒训练(不清洗,让模型自己扛)

业界谱系:label smoothing(已用)→ 广义交叉熵 GCE → co-teaching(双模型互挑低 loss 样本)→ DivideMix(loss 分布 GMM 软分干净/噪声池 + 半监督)。后两者工程重,VLM SFT 场景性价比低。

本项目落地 = 软化通道(2026-08-04):

- `sample_weights` 双语义: $w > 1$  物理复制(hard-mining 原有)/  $0 < w < 1$  → 该样本整条 loss 降权(data.py 乘进 per-token weights,仅 train 生效,val 不动;已单测)
- 资产:`labels_dedup_softclean.jsonl`(83,561 全保留:1933 修正 + 2307 降权 0.3)+ `suspect_weights.json`
- 软化 vs 硬删的哲学:单证嫌疑 precision 有限(~50-70%),硬删会错杀真难例;降权 0.3 = "可疑标签只发 30% 的声音",保信息量、控噪声,期望损失严格优于二选一赌博
- 清洗夜建议跑软化臂(对照:原始 / 硬删 81254 / 软化 83561)

## 7. 主观边界正规化(清不动的,改造它)

业界结论(learning from disagreement / CrowdTruth):标注员分歧是信号不是噪声;对本质模糊的边界,强行仲裁 = 制造伪确定性。

本项目对应纪律(全部已建):

- A↔D:无正面证据不判(D 是兜底不是"陌生人");76% 本质不可判,不清、不调模型,弹药押 SubKS
- C:只升级不降级(描述/帧没写威胁 ≠ 视频无威胁;Gemini 读不出犯罪意图是它的盲区)
- k/l/m:文本方向不可靠,judge 互不改判
- 层级兜底:KS 父类 acc(6 类)对边界混淆免疫,是更稳的汇报口径
- 后续可选:对边界桶用软标签(A/D 各 0.5)训练,把"不确定"显式教给模型

## 8. 测试集卫生(脏尺子怎么用)

铁律:测试集只读诊断,永不清洗(冻结基准 = 客户验收的尺子;改它 = 分数不可比 + 越权)。

共享错标幻觉(本项目实测,反直觉但已三口径验证):

- 522 条测试错标里,模型附和错 GT 301 条 vs 模型判对被冤 100 条 = 3:1 —— 模型从训练集背下了同一套错标映射
- 三口径对比(单模):全量 RT 83.37 / 剔 522 → 84.65(+1.3)/ 把 522 改成正确标签 → 81.55(-1.8)
- 推论:清训练集 → 模型学对 → 在 test 的 301 条共享错标上"答对被判错" → test RT 下降但真实质量上升。所以清标验收看 SubKS + 人工,永远不看 test RT。

双口径管线(已接入 eval\_metrics.py + night\_chain.sh):官方全量(11022)永远第一、gating 只认它;去噪口径(RT 剔 522 / SubKS 剔 622)只做附加诊断。剔除口径必须 model-independent(judge/盲判都不看被测模型)。

Platinum 子集(业界:ImageNet-Real/CIFAR-N 的路):bucket ③ 高嫌疑 115 条送人工终审,可产出"白金子集"作为第三报告口径。

## 9. 多证人合议架构(本项目的核心方法论)

| 证人                     | 看什么          | 盲区                    |
|------------------------|--------------|-----------------------|
| desc-judge(Gemini 纯文本) | GT 描述 ↔ 标签自治 | 描述没写出来的错标;类定义写错则系统性误杀 |
| Gemini 16帧盲判           | 帧 ↔ 标签       | 读不出犯罪意图(C类);与模型共享帧局限  |
| 我方模型预测 / CL            | 训练分布 ↔ 标签    | 已背下的共享错标(与噪声同源)       |
| 训练动力学                  | loss 轨迹形状    | 需要一次完整训练;重复样本稀释信号     |
| 人工终审                   | 一切           | 贵,只审高嫌疑交集             |

决策规则:双证人同向 → 修正;单证 → 降权(软化)或删除;证人矛盾 → 人工;涉 C/安全类 → 只升级。

评测剔除口径的唯一合法证人组合:desc-judge + 盲判(均不看被测模型)。

## 10. 行动手册(下一步)

- 1. 清洗夜实验矩阵(单变量纪律,每臂只动一处):
  - 臂 A:原始 labels\_dedup(基线复跑,带 --cartography)
  - 臂 B:软化 softclean + suspect\_weights(推荐主臂)
  - 臂 C(可选):硬删 clean 81254
  - 全臂统一:--ckpt-every 200 --resume 断点保护;验收 = SubKS  $\geq$  基线 & 安全召回不降;不看 test RT
- 2. cartography 出图 → 高方差桶  $\cap$  嫌疑清单交叉 → 迭代第二轮清洗
- 3. 增强 v2 消融(S2b2 门禁)可与清洗夜合并排期:clean 数据  $\times$  (v2 开/关)
- 4. SubKS e → b 424 条系统性错标 → 训练集同方向 desc-judge(预计放大到 ~3000+ 条),纳入下轮清洗
- 5. bucket ③ 115 条 + CL  $\cap$  judge 差集抽样 → 人工终审 → platinum 子集

## 参考文献

- Northcutt et al., \*Confident Learning: Estimating Uncertainty in Dataset Labels\*, JAIR 2021
- Northcutt et al., \*Pervasive Label Errors in Test Sets Destabilize ML Benchmarks\*, NeurIPS 2021
- Swayamdipta et al., \*Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics\*, EMNLP 2020
- Pleiss et al., \*Identifying Mislabeled Data using the Area Under the Margin Ranking\*, NeurIPS 2020
- Han et al., \*Co-teaching: Robust Training of DNNs with Extremely Noisy Labels\*, NeurIPS 2018
- Li et al., \*DivideMix: Learning with Noisy Labels as Semi-supervised Learning\*, ICLR 2020
- Beyer et al., \*Are we done with ImageNet?\*(ImageNet-Real), 2020
- Wei et al., \*Learning with Noisy Labels Revisited\*(CIFAR-N), ICLR 2022
- Ratner et al., \*Snorkel: Rapid Training Data Creation with Weak Supervision\*, VLDB 2017
- Penedo et al., \*The FineWeb Datasets\*, NeurIPS 2024