

数据噪声治理实战手册(Data-Centric AI Playbook)

Anker VLM 项目 · 2026-08-04 · 基于业界方法综述 + 本项目全部实测数据

配套 PDF: docs/data_centric_noise_playbook.pdf

0. 摘要

大模型时代的共识: 模型架构的边际收益递减, 数据质量的边际收益仍然陡峭(data-centric AI)。

本项目的标签噪声治理已覆盖业界六大方法族中的全部可用项, 核心结论:

- 1. 我们的组合拳(描述 judge + 多证人合议 + 只升级纪律 + 删改分层 + 评测双口径)与业界 SOTA 实践一一对应, 方向无需调整;
- 2. 新补齐三件套: 训练动力学日志(--cartography)、嫌疑软化通道(loss 降权)、置信学习交叉验证;
- 3. 反直觉铁律(实测): 清训练集会让冻结 test 的 RT 分不升反降(共享错标幻觉), 清标验收只看 SubKS/人工, 永远不看 test RT。

1. 病情画像

维度	数字	来源
训练集	83,561 条(去重后)	labels_dedup.jsonl
测试集	11,022 条, 冻结、客户已验、永不清洗	labels_test.jsonl
RT 训练集错标(desc-judge)	4,240 = 5.1%(D 3061 / A 1075 / B 90 / E 14)	gt_desc_judge_train.jsonl
RT 测试集错标(desc-judge)	522 = 4.7%(D 8.5% > A 5.9% > E 0.8% > B 0.3% > C 0%)	test_mislabel_exclude_ids_522.txt
SubKS 测试集错标(desc-judge, 终稿)	198 = 1.8%(m→p野生/m→a/g→i 为主)	test_sk_mislabel_exclude_ids.txt
SubKS 两证人嫌疑上限	882 = 8.0%(含主观边界, 不可直接当错标)	模型 × 盲判交叉
本质模糊(全片都判不了)	RT 错误的 49% / SubKS 错误的 66%	16 帧盲判分解
关键帧缺失真实上限	RT 1.48pp / SubKS 4.01pp(事件类双双漏判)	同上

噪声结构三分: ①客观错标(描述自打脸, 可清)②主观边界(A↔D、e/f/m、k/l, 清不动, 只能软化)③瞬时事件漏标(帧间证据, 需客户侧重切, 收益上限小)。

2. 方法族总览

#	方法族	代表工作	本项目状态
1	置信学习	Cleanlab / Northcutt 2021	已跑(CL 615 条, ∩ judge 72 = 证人互补)
2	LLM-as-Judge 清洗	FineWeb, Nemotron-CC	主力(RT 4240 / SK 终稿 198, 撤 judge 定义错 617)
3	训练动力学	Dataset Cartography / AUM	已落码(--cartography), 清洗夜启用
4	噪声鲁棒训练	label smoothing / co-teaching / DivideMix	软化通道已落码(降权 0.3)
5	主观边界正规化	learning from disagreement	纪律已建(只升级/不判 k-l-m)
6	测试集卫生	ImageNet-ReaL / CIFAR-N	双口径已接管线

3. 置信学习(Confident Learning)

原理:对每类 j 估计"被标为 j 的样本的平均预测概率"作为类阈值 t_j ;样本(标 i)若对某类 $j \neq i$ 的预测概率 $\geq t_j$,计入混淆联合 $C[i][j]$ 的 off-diagonal $\rightarrow$ 嫌疑。比裸 argmax 稳健(类不平衡下阈值自适应)。

经典结论(Pervasive Label Errors, Northcutt 2021):ImageNet test 有 $\sim 6\%$

错标;模型会背测试集错标刷分,测试集越脏、大模型优势越被低估。本项目"剔 522 后 RT +1.26pp"就是该现象的复现。

本项目实测(S5 模型 RT 字母 logits, test 11022):

- CL 嫌疑 615 = 5.6%;方向 $A \rightarrow D$ 236 / $D \rightarrow A$ 141(主观边界为主)
- 与 judge 522 只重合 72 条 —— 两个证人盲区互补:CL 看不见"模型已背下的共享错标"(模型附和错 GT 时 CL 无信号);judge 看不见"描述没写出来的错标"
- $\triangle$ CL 清单(`cl_rt_suspects_test.json`)只能用于训练集清洗排序/人工审计,绝不可当评测剔除口径(它使用了被测模型,不满足 model-independent)

落地:清洗夜产出新模型后,用其 train 集 logits 跑 CL,与 desc-judge 4240 取交集 = 最高置信错标(优先修),取差集 = 各自盲区(送人工抽审)。

4. LLM-as-Judge 清洗(主力方法)

设计要素(业界共识 $\leftrightarrow$ 本项目实现):

- 1. 只抓肯定性矛盾,模糊一律 ok("vague $\rightarrow$ ok")—— 宁漏抓保精度
- 2. 要求引用证据(cue 字段 ≤ 12 词原文引用)—— rationale-required,防幻觉
- 3. prompt 约束 + 代码硬闸双保险(ALLOWED_TARGETS / NEVER_DEMOTE / 身份闸)
- 4. 试跑(分层抽样) $\rightarrow$ 人工目测 $\rightarrow$ 收紧 $\rightarrow$ 全量,迭代闭环
- 5. 删除比改判安全:三层口径 = 有旁证才修(1933)/ 单证只删或降权(2307)

两次实战教训:

- 第一轮试跑暴露"多主体场景"与"干活途中碰车"两个误杀模式 $\rightarrow$ prompt 加 MAIN-activity 约束,嫌疑率 4.1% $\rightarrow$ 3.0%
- SubKS 审计先后抓出 judge 自身的两个类定义错误(共撤回 test 617/827 条 flag):① $m \rightarrow p$: p =野生动物且父类 LifeThreat,家猫家狗标 $E|m$ 本来就对;② $e \rightarrow b$: b =【家人】遛狗,路人($RT=D$)遛狗= e 正确——曾被误判为"标注系统性错标 424 条",实为 judge 望文生义。双重教训:SubKS 多为【身份 $\times$ 场景】联合定义,judge 的类定义必须逐条经客户语义确认;凡"单方向占比异常高"先怀疑 judge 而不是标注。

5. 训练动力学(Dataset Cartography / AUM)

原理:训练过程中每样本每次相遇的 loss/margin 轨迹,天然把数据分三桶:

- 易学(低 loss 低方差)= 干净样本
- 难学但稳定(高 loss 低方差)= 真难例(保留!是泛化的养分)
- 高波动/低置信(高方差)= 疑似错标

这是唯一能区分"错标 vs 真难例"的免费证人——desc-judge 和 CL 都做不到这一点。

本项目实现(`train_sft.py --cartography`, 2026-08-04):

- `loss_fn` 借 `has_aux` 返回每样本加权 CE,零额外前向;宿主用 `draw()` 纯函数反推 `video_id`,预取器零改动
- 输出 `<out>/cartography.jsonl`: {video_id, micro, loss}, $\sim 4.7 \text{ epoch} \times 83k \approx 39 \text{ 万行}$

- 分析:按 video_id 聚合 → 均值(难度) × 方差(波动)二维图 → 高方差桶 $\cap$ judge/CL 嫌疑 = 铁证错标;高均值低方差 $\cap$ 嫌疑 = 大概率真难例,从清洗清单摘除

用法:清洗夜训练命令加 `--cartography`,一次训练白捡第四证人。

6. 噪声鲁棒训练(不清洗,让模型自己扛)

业界谱系:label smoothing(已用)→ 广义交叉熵 GCE → co-teaching(双模型互挑低 loss 样本)→ DivideMix(loss 分布 GMM 软分干净/噪声池 + 半监督)。后两者工程重,VLM SFT 场景性价比低。

本项目落地 = 软化通道(2026-08-04):

- `sample_weights` 双语义: $w > 1$ 物理复制(hard-mining 原有)/ $0 < w < 1$ → 该样本整条 loss 降权(data.py 乘进 per-token weights,仅 train 生效,val 不动;已单测)
- 资产:`labels_dedup_softclean.jsonl`(83,561 全保留:1933 修正 + 2307 降权 0.3)+ `suspect_weights.json`
- 软化 vs 硬删的哲学:单证嫌疑 precision 有限(~50-70%),硬删会错杀真难例;降权 0.3 = "可疑标签只发 30% 的声音",保信息量、控噪声,期望损失严格优于二选一赌博
- 清洗夜建议跑软化臂(对照:原始 / 硬删 81254 / 软化 83561)

7. 主观边界正规化(清不动的,改造它)

业界结论(learning from disagreement / CrowdTruth):标注员分歧是信号不是噪声;对本质模糊的边界,强行仲裁 = 制造伪确定性。

本项目对应纪律(全部已建):

- A↔D:无正面证据不判(D 是兜底不是"陌生人");76% 本质不可判,不清、不调模型,弹药押 SubKS
- C:只升级不降级(描述/帧没写威胁 ≠ 视频无威胁;Gemini 读不出犯罪意图是它的盲区)
- k/l/m:文本方向不可靠,judge 互不改判
- 层级兜底:KS 父类 acc(6 类)对边界混淆免疫,是更稳的汇报口径
- 后续可选:对边界桶用软标签(A/D 各 0.5)训练,把"不确定"显式教给模型

8. 测试集卫生(脏尺子怎么用)

铁律:测试集只读诊断,永不清洗(冻结基准 = 客户验收的尺子;改它 = 分数不可比 + 越权)。

共享错标幻觉(本项目实测,反直觉但已三口径验证):

- 522 条测试错标里,模型附和错 GT 301 条 vs 模型判对被冤 100 条 = 3:1 —— 模型从训练集背下了同一套错标映射
- 三口径对比(单模):全量 RT 83.37 / 剔 522 → 84.65(+1.3)/ 把 522 改成正确标签 → 81.55(-1.8)
- 推论:清训练集 → 模型学对 → 在 test 的 301 条共享错标上"答对被判错" → test RT 下降但真实质量上升。所以清标验收看 SubKS + 人工,永远不看 test RT。

双口径管线(已接入 eval_metrics.py + night_chain.sh):官方全量(11022)永远第一、gating 只认它;去噪口径(RT 剔 522 / SubKS 剔 622)只做附加诊断。剔除口径必须 model-independent(judge/盲判都不看被测模型)。

Platinum 子集(业界:ImageNet-Real/CIFAR-N 的路):bucket ③ 高嫌疑 115 条送人工终审,可产出"白金子集"作为第三报告口径。

9. 多证人合议架构(本项目的核心方法论)

证人	看什么	盲区
desc-judge(Gemini 纯文本)	GT 描述 ↔ 标签自治	描述没写出来的错标;类定义写错则系统性误杀
Gemini 16帧盲判	帧 ↔ 标签	读不出犯罪意图(C类);与模型共享帧局限
我方模型预测 / CL	训练分布 ↔ 标签	已背下的共享错标(与噪声同源)
训练动力学	loss 轨迹形状	需要一次完整训练;重复样本稀释信号
人工终审	一切	贵,只审高嫌疑交集

决策规则:双证人同向 → 修正;单证 → 降权(软化)或删除;证人矛盾 → 人工;涉 C/安全类 → 只升级。

评测剔除口径的唯一合法证人组合:desc-judge + 盲判(均不看被测模型)。

10. 行动手册(下一步)

- 1. 清洗夜实验矩阵(单变量纪律,每臂只动一处):
 - 臂 A:原始 labels_dedup(基线复跑,带 --cartography)
 - 臂 B:软化 softclean + suspect_weights(推荐主臂)
 - 臂 C(可选):硬删 clean 81254
 - 全臂统一:--ckpt-every 200 --resume 断点保护;验收 = SubKS ≥ 基线 & 安全召回不降;不看 test RT
- 2. cartography 出图 → 高方差桶 ∩ 嫌疑清单交叉 → 迭代第二轮清洗
- 3. 增强 v2 消融(S2b2 门禁)可与清洗夜合并排期:clean 数据 × (v2 开/关)
- 4. SubKS train judge 净错标 1997 条(g→i 689 最大:快递放件标成访客)→ 并入下版软化资产(RT+SK 双维)
- 5. bucket ③ 115 条 + CL∩judge 差集抽样 → 人工终审 → platinum 子集

参考文献

- Northcutt et al., *Confident Learning: Estimating Uncertainty in Dataset Labels*, JAIR 2021
- Northcutt et al., *Pervasive Label Errors in Test Sets Destabilize ML Benchmarks*, NeurIPS 2021
- Swayamdipta et al., *Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics*, EMNLP 2020
- Pleiss et al., *Identifying Mislabeled Data using the Area Under the Margin Ranking*, NeurIPS 2020
- Han et al., *Co-teaching: Robust Training of DNNs with Extremely Noisy Labels*, NeurIPS 2018
- Li et al., *DivideMix: Learning with Noisy Labels as Semi-supervised Learning*, ICLR 2020
- Beyer et al., *Are we done with ImageNet?*(ImageNet-ReaL), 2020
- Wei et al., *Learning with Noisy Labels Revisited*(CIFAR-N), ICLR 2022
- Ratner et al., *Snorkel: Rapid Training Data Creation with Weak Supervision*, VLDB 2017
- Penedo et al., *The FineWeb Datasets*, NeurIPS 2024